

Trabajo práctico Final

Redes Neuronales Convolucionales

Integrantes:

Melanie Natasha Mauas (63517)

Agostina Almendros (63096)

Modelo Simple de MLP




Imagen 1 : train/accuracy modelo simple




Imagen 2 : train/loss modelo simple




Imagen 3 : val/accuracy modelo simple




Imagen 4 : val/loss modelo simple




Imagen 5 : matriz de confusión modelo simple

El modelo fue entrenado utilizando un conjunto de datos multiclase y evaluado mediante métricas de pérdida y exactitud tanto para el conjunto de entrenamiento como de validación. Durante las primeras épocas, se observó una disminución progresiva y estable del `train_loss`, acompañado de un aumento sostenido de `train_accuracy`. Esto indica una buena capacidad de aprendizaje del modelo sobre los datos de entrenamiento.

En cuanto al conjunto de validación, la `val_loss` mostró una tendencia decreciente inicial hasta llegar a un mínimo, pero posteriormente comenzó a aumentar ligeramente, lo que sugiere el inicio de un fenómeno de `overfitting`. Esta hipótesis se refuerza con la observación de la `val_accuracy`, que si bien creció hasta un 90%, comenzó a estabilizarse o decrecer levemente en las últimas épocas. Este comportamiento indica que el modelo comienza a ajustarse demasiado a los datos de entrenamiento y pierde capacidad de generalización.

La matriz de confusión revela un buen desempeño general, con la mayoría de las predicciones correctamente ubicadas sobre la diagonal. Sin embargo, se evidencian algunas confusiones entre clases específicas —en particular entre la clase 0 y 4, y entre la clase 2 y 3— lo cual sugiere una posible similitud entre estas categorías que podría abordarse con técnicas de recolección de más datos, aumento de datos (`data augmentation`) o modificaciones en la arquitectura.

En conjunto, los resultados obtenidos son satisfactorios. Sin embargo, para mejorar la generalización y mitigar el overfitting, se podrían aplicar estrategias adicionales como early stopping, regularización L2, o dropout. Como se realizó en el trabajo integrador.

Este modelo logró una exactitud de entrenamiento del 65.71% y de validación del 57.46%, aunque mostró signos de overfitting hacia las últimas épocas. Con el objetivo de mejorar la capacidad de generalización y explotar la estructura espacial implícita en los datos, se implementará una red neuronal convolucional (CNN).

Modelo con CNN

Las CNN están especialmente diseñadas para capturar patrones espaciales jerárquicos y se espera que ofrezcan mayor robustez ante ruido, así como una mejor discriminación entre clases con características similares. En esta sección se compararán ambos enfoques en cuanto a rendimiento, capacidad de generalización, complejidad computacional y capacidad de aprendizaje.




Imagen 6: train/accuracy modelo CNN




Imagen 7: train/loss modelo CNN




Imagen 8 : val/accuracy modelo CNN




Imagen 9 : val/loss modelo CNN




Imagen 10 : matriz de confusión modelo CNN

Para poder realizar este trabajo nosotras decidimos reemplazar el ciclo de búsqueda de hiperparametros, porque implicaba entrenar una amplia cantidad de modelos diferentes. Generando así ejecuciones largas, con altos tiempos de procesamiento.

Para poder cumplir con el objetivo, y llegar a comparar la performance del modelo MLP contra CNN no era estrictamente necesario explorar todas las combinaciones posibles. Por ello, optamos por fijar una única configuración de hiperparametros y entrenar una sola CNN.

De esta manera priorizamos la comparación en metodología de ambos modelos.

Para la CNN utilizamos CNNClassifier, adaptándola a un tamaño de entrada fijo de 64x64 pixeles. La resolución no es tan alta pero permite entrenar rápido y es la suficiente para poder diferenciar patrones generales en imágenes de piel.

La arquitectura elegida fue elegida por diferentes razones:

- Tiene capas convolucionales con filtros para extraer características espaciales (textura, bordes, colores).
- Incluye capas de pooling que reducen la dimensionalidad y evitan overfitting.
- Tiene capas fully connected finales que permiten clasificar en múltiples clases.
- Admite HPs como dropout, que ayuda a reducir overfitting.

Hiperparametros:

- **Input size:** 64 x 64.
Tamaño bajo para acelerar el entrenamiento y disminuir el consumo de memoria. Para imágenes de piel, incluso resoluciones pequeñas conservan patrones de color y textura útiles.
- **Learning rate (lr):** 1e-3.
Un valor estándar para optimizadores tipo Adam, lo suficientemente grande para converger en pocas épocas, pero sin provocar inestabilidad.
- **Batch size:** 32.
Equilibrio entre velocidad y estabilidad de gradientes.
- **Dropout:** 0.3.
Reduce el overfitting en las capas fully connected.
- **Epochs:** 30.
Suficiente para ver convergencia en el conjunto pequeño.
- **Early stopping (es_patience):** 5.
Evita entrenar innecesariamente si el modelo deja de mejorar.
- **Optimizador:** Adam.
Más estable y eficiente que SGD en problemas con pocos datos y ruido.
- **Data augmentation:** flips horizontales y verticales, y ajuste de brillo/contraste.
Simular variabilidad en las imágenes y mejorar la generalización.

Epoch 30:

Train Loss: 0.3906, Accuracy: 86.66%

Val Loss: 0.9709, Accuracy: 70.17%

Métrica	MLP (perceptrón multicapa)	CNN (red convolucional)	Comparación
Train Accuracy	65,7%	86,7%	mejora notable con CNN
Val Accuracy	57,5%	70,2%	mejora notable con CNN
Train loss	0,897	0,3906	CNN generaliza mejor
Val loss	1,189	0,9709	CNN ajusta mejor al val set

Tabla 1 : tabla comparativa de las métricas entre MPL simple y modelo con CNN

Confusion Matrix (Validación)

MLP:

- Bastante confusión entre clases similares (por ejemplo, *Melanoma*, *Nevus*, *Carcinoma*).
- Bajo rendimiento en clases como *Actinic keratosis*, *Candidiasis*.

CNN:

- Mejora notable en:
 - Actinic keratosis (13 vs. 9 correctas en MLP).
 - Melanocytic nevus (13 vs. 10).
 - Squamous cell carcinoma (13 vs. 9).
- En general, las clases están mejor separadas: CNN extrae mejor las características visuales.

Curvas de entrenamiento

MLP:

- Aprendizaje más lento.
- Menor accuracy y mayor pérdida en validación.
- Ligeramente más ruido y fluctuaciones.

CNN:

- Curvas suaves y consistentes.
- Mayor capacidad de aprendizaje sin overfitting aparente hasta el epoch 29.
- Indicador de buen ajuste a los datos sin sobreentrenamiento.

Conclusiones

A partir de los resultados obtenidos, podemos concluir que el modelo basado en redes neuronales convolucionales (CNN) es significativamente superior al MLP en la tarea de clasificación de imágenes de piel. Esto era esperable, dado que las CNN están especialmente diseñadas para trabajar con datos de tipo imagen, ya que pueden capturar patrones espaciales como bordes, texturas y formas.

En cambio, el MLP trata cada píxel como una característica independiente, sin tener en cuenta las relaciones espaciales entre ellos. Esta es una limitación importante en problemas de visión por computadora, donde justamente la información espacial es clave para distinguir las clases.

Además, el entrenamiento de la CNN con un conjunto razonable de hiperparámetros permitió lograr buenos niveles de precisión sin un tiempo de cómputo excesivo, lo cual hace viable su uso incluso en entornos con recursos computacionales limitados.

Por lo tanto, se concluye que, para este problema, la CNN no solo ofrece mejores métricas de desempeño en términos de accuracy y pérdida, sino que representa una elección metodológicamente más adecuada para el tipo de datos con el que se trabaja.